GACHON HCI LAB · 2026

웨어러블 기반 우울증 예측

GLOBEM 데이터셋 구현 및 개선 과정

v1 XGBoost → v2 결측 고도화 → v3 LightGBM

v1	v2	v3
0.558	0.557	0.568
기초 구현	결측 고도화	LightGBM

v3 기준 Depresjon AUC 0.845

Table of Contents

전체 구현 과정

01 연구 배경 & 데이터셋

GLOBEM vs Depresjon — 왜 어려운가

02 v1 — 기초 구현

XGBoost + 전체 중앙값 → AUC 0.558

03 v2 — 결측 처리 고도화

Person-level Imp. + Missing Flag → AUC 0.557

04 v3 — LightGBM 전환

NaN 직접 처리 → AUC 0.568

05 성능 종합 비교 & 해석

SHAP 분석 + 써카디안 기여도 변화

06 한계 & 다음 단계

왜 0.57인가 + 향후 방향

01 연구 배경 & 데이터셋

GLOBEM vs Depresjon — 왜 어려운가

데이터셋 비교

Depresjon vs GLOBEM

항목	Depresjon	GLOBEM (INS-W 1~4)
참여자	23명	대학생 수백 명 (4개년)
레이블	임상 진단 PHQ-8	주간 PHQ-9 자가보고
양성 비율	34.8%	44.4%
피처 수	36개 (allday)	127개 (5개 시간대)
결측률	~5% (입원 환경)	58.5% (일상 착용)
써카디안	DLMO·CBTmin 포함	IS/IV 간접 추정
최종 AUC	**0.845**	**0.558 → 0.568 (v3)**

0.845
Depresjon AUC

0.568
GLOBEM v3 AUC

왜 성능 차이가 나는가

Depresjon은 입원 환경의 강한 신호 + 낮은 결측률 → AUC 0.845 가능. GLOBEM은 일상 대학생 + 경증 신호 + 결측 58.5% → 훨씬 어려운 문제. 단순히 모델만 좋게 해서는 해결 안 되는 데이터 자체의 한계가 있음.

핵심 문제

결측률 58.5%가 핵심 장벽

58.5%

전체 피처 결측률

127개 피처 × 6,435행

70%

행 제거 기준

이 이상 결측 시 해당 행 삭제

364,353

모델에 전달된 NaN 수

v3 기준 (imputation 없음)

왜 결측이 이렇게 많은가?

① 시간대별 피처 설계

하루를 allday / morning / afternoon / evening / night 5구간으로 나눔
특정 시간대에 Fitbit을 안 차면 해당 구간 전체가 NaN

② 대학생 일상 착용 패턴

수업·아르바이트 등으로 착용이 불규칙
특히 afternoon / evening 구간 결측 빈번

③ 디바이스 미착용 자체가 신호

우울할수록 디바이스를 방치하는 경향
결측이 랜덤이 아니라 우울과 연관될 수 있음

02 v1 — 기초 구현

XGBoost + 전체 중앙값 Imputation → AUC 0.558

v1 파이프라인

첫 번째 구현 — 설계 & 선택

01 피처 설계

수면 80개 + 걸음수 45개
= 총 125개 피처
5개 시간대 × RAPIDS 집계

02 IS/IV 계산

시간대별 걸음수 4개로
Interdaily Stability
Intradaily Variability 계산

03 결측 처리

행 결측 70% 초과 제거
나머지는 전체 중앙값으로 대체
→ 127개 피처 확정

04 모델 학습

XGBoost
Bayesian Optimization
(Hyperparameter 탐색)

05 평가

StratifiedGroupKFold
5-fold CV
(참여자 단위 분리)

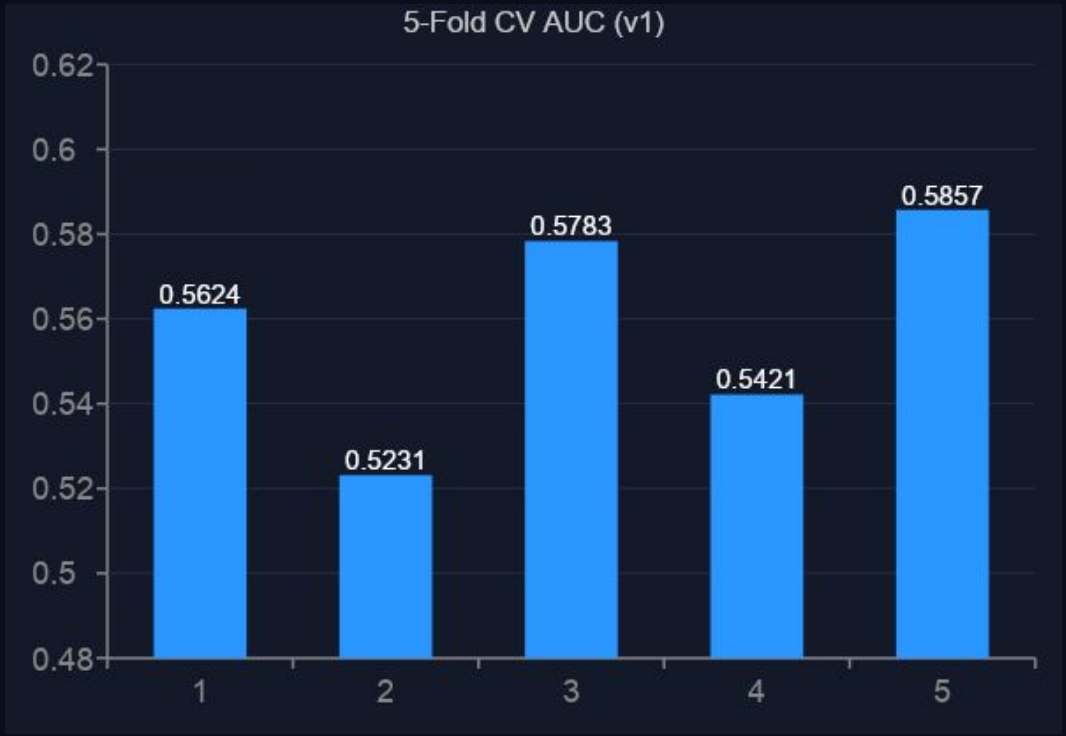
결과

AUC 0.5583 ± 0.0231

⚠ 발견된 문제

전체 중앙값으로 결측 대체 → 개인차 무시
착용 안 한 날을 '평균적인 날'로 위장

SHAP 피처 중요도 & 5-fold CV



Mean AUC

0.5583 ± 0.0231

SHAP 피처 그룹 기여도

Sleep / Activity

Circadian (IS/IV + timing) **13.5%**

상위 피처

- avgdurationinbed:allday
- lastbedtime:allday
- ratiodurationasleep:morning
- circ_IS
- firstwaketime:allday

03 v2 — 결측 처리 고도화

Person-level Imputation + Missing Flag → AUC 0.557

v1의 전체 중앙값 대체, 무엇이 문제인가?

전체 중앙값 대체 (v1)

예시: 수면 시간 결측 처리

참여자 A (평균 6시간)

6.2h | NaN | 6.1h | NaN | 6.3h → 6.5h

← 전체 중

참여자 B (평균 8시간)

8.1h | NaN | 7.9h | NaN | 8.2h → 6.5h

← 전체 중

문제: A의 결측에도, B의 결측에도 같은 6.5h를 채움 → 개인차 완전 무시

v2 개선 방향

① Person-level Imputation

NaN → 그 사람의 이력 중앙값
A의 결측: 6.2h, B의 결측: 8.1h
개인 baseline 보존

② Missing Flag 피처

결측 여부를 0/1로 저장
'착용 안 함' 자체를 신호로 활용
97개 플래그 피처 추가

③ IS/IV 써카디안 복원

v1에서 누락된 IS/IV 재추가
SHAP 기여도 13.5% 유지 확인
127개 → 224개 피처

v2 결과

개선 시도 결과 & 한계 발견

항목	v1 (기존)	v2 (개선)	변화
Imputation	전체 중앙값	개인별 중앙값 → fallback	개인 baseline 보존
Missing 신호	없음	이진 플래그 97개 추가	+97개 피처
IS/IV	포함 (13.5%)	복원 (13.7%)	동일 수준
피처 수	127개	224개	+97 플래그
AUC	**0.5583**	**0.5574**	**-0.0009**

잔여 NaN

283,140개

person-level 후에도 남은 결측

핵심 발견

결측 처리 방식을 바꾼다고 AUC가 오르지 않음
문제는 XGBoost가 NaN을 처리하는 구조적 한계

결론: 채우는 방법을 바꾸는 것이 아니라, NaN을 아예 채우지 않아도 되는 모델로 전환이 필요

04 v3 — LightGBM 전환

NaN을 직접 처리 → AUC 0.568 (+0.0098)

왜 LightGBM인가?

XGBoost (v1, v2) — 문제

- NaN을 직접 처리하지 못함
- 학습 전 반드시 값을 채워야 함 (Imputation 필수)
- 채운 값 = 노이즈 (원래 정보 손실)
- 착용 안 한 날 → 평균적인 날로 둔갑
- 결측 283,140개가 모두 가짜 데이터로 학습

VS

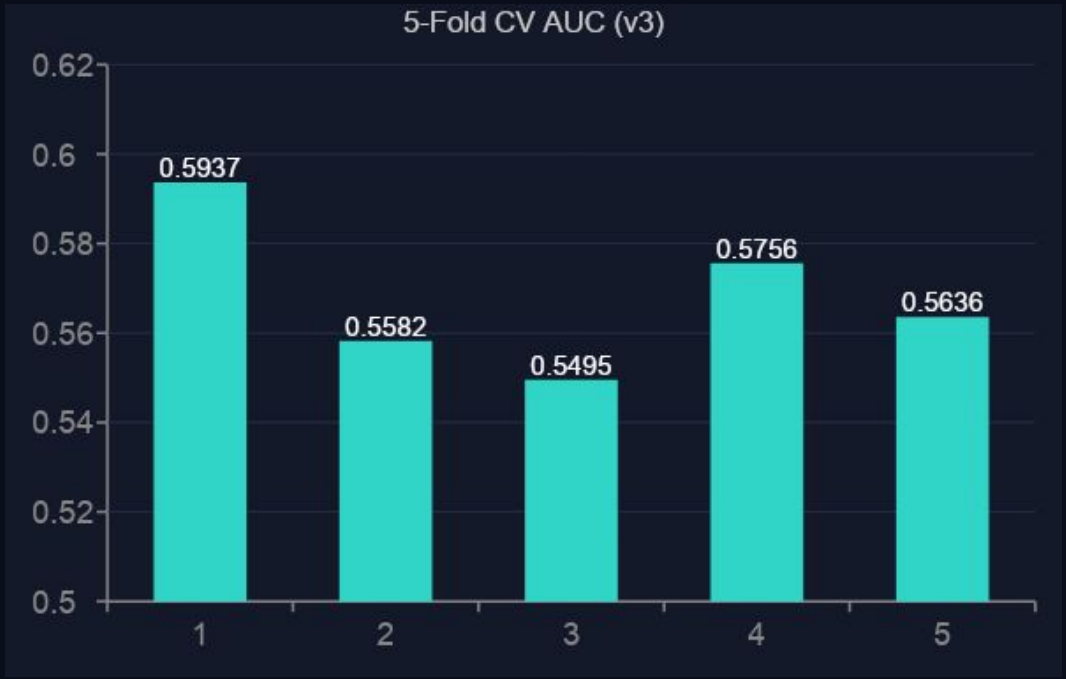
LightGBM (v3) — 해결

- NaN을 그대로 모델에 전달
- 트리 분기 시 NaN을 별도 경로로 처리
- 값이 없다 자체가 학습 신호
- 착용 안 한 날 → 독립적인 패턴으로 인식
- 결측 364,353개가 모두 정보로 활용

핵심: Imputation은 없는 값을 있는 것처럼 위장. LightGBM은 없는 것을 없는 그대로 학습. 결측 58.5%가 노이즈에서 신호로 바뀐 것이 AUC +0.0098의 이유.

v3 결과

LightGBM — 첫 유의미한 성능 향상



0.5681

Mean AUC

±0.0153

+0.0098

vs v1

XGBoost 대비

127개

피처 수

v2 224개에서 감소

v2 대비 주요 변화

- Imputation 코드 완전 제거
- Missing flag 97개 불필요
- StandardScaler 제거 (LightGBM 스케일 무관)
- 써카디안 SHAP: 13.7% → 27.3%

SHAP 기여도

Sleep/Activity 72.7%

Circadian IS/IV 27.3%

05 성능 종합 비교 & 해석

v1 → v2 → v3 전체 흐름 + SHAP 변화

종합 성능 비교

Depresjon vs GLOBEM v1 / v2 / v3

0.845

AUC (5-fold CV)

Depresjon

수면30 + Circadian6

0.558

AUC (5-fold CV)

GLOBEM v1

XGBoost + 전체중앙값

0.557

AUC (5-fold CV)

GLOBEM v2

XGBoost + person-level

결측고도화

0.568

AUC (5-fold CV)

GLOBEM v3

LightGBM + No Imp.

최고성능

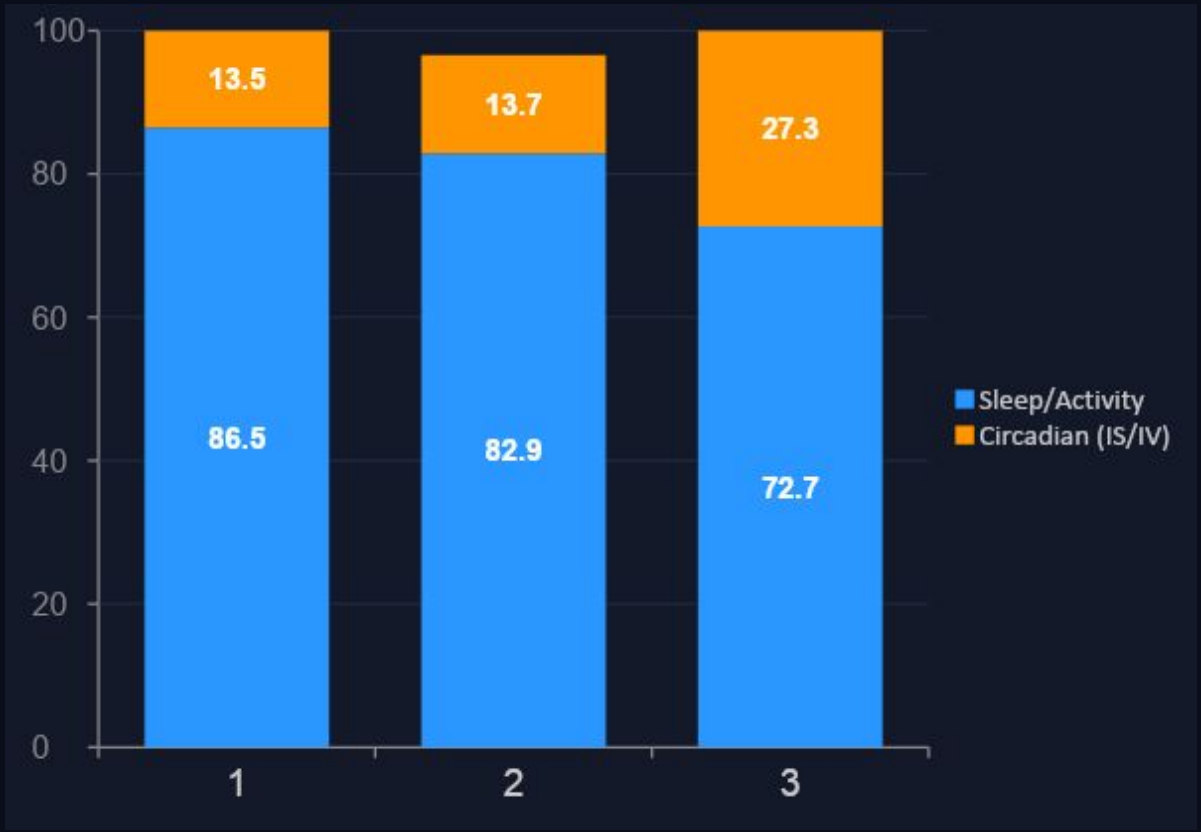
SHAP 피처 기여도 변화

구분	Sleep/Activity	Circadian (IS/IV)	Missing Flag	피처수	AUC
Depresjon	90.3%	9.7%	—	36개	0.845
GLOBEM v1	86.5%	13.5%	—	127개	0.558
GLOBEM v2	82.9%	13.7%	3.3%	224개	0.557
GLOBEM v3 ★	**72.7%**	**27.3%**	—	**127개**	**0.568**

주목 포인트

- v2→v3: 피처 수 줄었지만 성능 향상
- 써카디안 13.5%→27.3% 두 배
- 결측이 노이즈→신호로 전환

써카디안 SHAP 13.5% → 27.3%



왜 v3에서 써카디안이 두 배가 됐나?

v1/v2에서는 결측을 중앙값으로 채워서
IS/IV의 고유 신호가 다른 피처들과 섞였어요.

v3의 LightGBM은 NaN을 별도 경로로 처리해서
IS/IV 신호가 더 선명하게 분리됐어요.

IS/IV가 실제로 중요한 생체 신호

써카디안 리듬 불규칙성(IS↓, IV↑)은
우울증의 핵심 생체 신호예요.

v3에서 27.3%까지 기여도가 오른 것은
모델이 리듬 정보를 더 정확히 학습한다는 의미예요.

Missing flag가 v3에서 필요 없는 이유

v2에서 수동으로 만든 missing flag(3.3%)
v3의 LightGBM이 자동으로 대체해요.

피처 224개 → 127개로 줄었지만
성능은 오히려 올랐어요.

06 한계 & 다음 단계

왜 여전히 AUC 0.57인가 + 향후 방향

왜 여전히 AUC 0.57에 머무르는가?

01

경증 코호트 — 신호 자체가 약함

GLOBEM은 일상생활 가능한 대학생
우울 신호 자체가 미약
입원 환자 수준의 신호와 근본적 차이

02

써카디안 피처 품질 한계

IS/IV는 걸음수 4구간 간접 추정
HR/체온 기반 Forger ODE 대비 부정확
HR 데이터가 GLOBEM에 미포함

03

잔여 결측 364,353개

LightGBM이 처리하지만
결측이 많을수록 학습 신호 약화
allday 전용으로 줄이면 개선 가능

04

단일 모델 & 피처 한계

트리 계열 모델만 시도
LSTM 등 시계열 모델 미시도
주간 패턴의 시계열 특성 미활용

다음 단계

AUC 향상 로드맵

완료

v1 — 기초 구현

- XGBoost + 전체 중앙값 imputation
- 127개 피처 (수면+걸음수+IS/IV)
- AUC 0.558 달성

→ 결측 처리 방식 문제 발견

완료

v2 — 결측 고도화

- Person-level imputation
- Missing-indicator 플래그 97개
- IS/IV 써카디안 복원

→ AUC 0.557 (효과 없음)

완료

v3 — LightGBM

- NaN 그대로 처리 (imputation 제거)
- 전체 127개 피처 사용
- 써카디안 SHAP 27.3%

→ AUC 0.568 (+0.0098)

다음

v4 — 써카디안 고도화

- Forger ODE로 CBTmin 추정
- HR 데이터 확보 및 통합
- DLMO 간접 추정

→ 성능 향상 핵심 방향

v3(LightGBM)으로 첫 유의미한 개선 달성. 써카디안 SHAP 27.3%는 리듬 피처의 중요성 확인. 다음은 HR 기반 써카디안 품질 향상이 핵심.

Summary

v1 → v2 → v3
무엇을 배웠는가

01 결측률이 핵심 장벽

58.5% 결측은 단순 imputation으로 해결 안 됨
모델 구조 변경이 더 효과적

02 방법론 변경 > 파라미터 튜닝

v2에서 imputation 방식을 바꿔도 AUC 변화 없음
v3에서 모델 자체를 바꾸자 +0.0098 개선

03 써카디안 리듬이 핵심 신호

IS/IV SHAP 13.5% → 27.3%
HR 데이터 통합 시 더 큰 향상 기대

04 데이터 한계 인식

GLOBEM의 0.57 vs Depresjon의 0.845
코호트 차이가 성능 차이의 근본 원인