웨어러블 기반 우울증 예측

GLOBEM 구현 — 두 트랙 통합 비교

같은 출발점(v1)에서 갈라진 두 실험 갈래의 종합 분석

Track A

XGBoost → LightGBM

v1 → v2 (Person-level Imp.) → v3 (LightGBM)

최고 AUC

0.5681

Track B

XGBoost → RandomForest

v1 → v2 (Missing Flag) → v3 (RA+Ratio) → v4 (RandomForest)

최고 AUC

0.5656

공통 출발점 : v1 XGBoost + 전체 중앙값 imputation → AUC 0.5583

Table of Contents

전체 구성

01 연구 배경 & 분기점

왜 v1에서 두 갈래로 나뉘었나

02 공통 출발점 — v1

XGBoost + 전체 중앙값 → AUC 0.558

03 Track A — LightGBM 트랙

결측을 직접 처리하는 방향 → AUC 0.568

04 Track B — RandomForest 트랙

새 써카디안 피처(RA) 설계 방향 → AUC 0.566

05 두 트랙 종합 비교

AUC, SHAP, 장단점 정면 비교

06 통합 다음 단계

두 트랙의 장점을 합친 v5 제안

01 연구 배경 & 분기점

왜 v1에서 두 갈래로 나뉘었나

실험 분기 구조

같은 v1에서 두 방향으로 분기

v1 (공통 출발점)

AUC 0.5583

Track A — LightGBM 방향

v2	Person-level imputation + Missing flag	**0.5574**
v3	LightGBM 전환 — imputation 완전 제거	**0.5681**

핵심 가설: 결측을 채우지 말고 모델이 직접 처리하게 하자

Track B — RandomForest 방향

v2	Person-level imputation + Missing flag	**0.5593**
v3	RA·Morning ratio 신규 써카디안 피처 추가	**0.5642**
v4	RandomForest 전환	**0.5656**

핵심 가설: 결측을 잘 채우고 새 써카디안 지표(RA)를 추가하자

02 공통 출발점 — v1

XGBoost + 전체 중앙값 Imputation → AUC 0.5583

v1 파이프라인

기초 구현 & 결측치 문제 발견

127개

피처 수

수면80+걸음수45+IS/IV2

58.5%

전체 결측률

시간대별 5구간 설계의 결과

0.5583

AUC (5-fold CV)

XGBoost + 전체 중앙값

v1의 핵심 한계 — 두 트랙 모두 여기서 출발

- 전체 중앙값으로 결측 대체 → 개인차 완전 무시 (수면 6시간인 사람과 8시간인 사람이 같은 값으로 채워짐)
- 착용 안 한 날이 '평균적인 날'로 위장되어 모델에 입력됨
- 써카디안 피처는 IS/IV 2개뿐 — 활동량 기반 단순 추정

→ 두 트랙 모두 "결측 처리"를 v2의 공통 개선 지점으로 선택했지만, 그 이후 방향이 갈라짐

03 Track A — LightGBM 트랙

결측을 직접 처리하는 모델로 전환 → AUC 0.5681

v2: Person-level Imputation + Missing Flag

개선 내용

① Person-level Imputation

개인 이력 중앙값으로 대체, 없으면 전체 중앙값 fallback

② Missing Flag 피처

결측 여부를 0/1로 저장, 97개 플래그 추가

③ IS/IV 복원

v1에서 쓰던 써카디안 프록시 유지

결과 & 한계

AUC 0.5574

v1 대비 -0.0009 (변화 없음)

핵심 발견

Imputation '방식'을 정교화해도 AUC는 거의 바뀌지 않음.

Person-level이든 전체 중앙값이든, XGBoost 입장에서는 둘 다 '가짜로 채운 값'이라는 점은 동일.

→ 문제는 채우는 방법이 아니라 '채워야 한다는 것' 자체

v3: LightGBM — Imputation 완전 제거

XGBoost (v1,v2)

- NaN을 직접 처리하지 못함
- 학습 전 imputation 필수
- 채운 값 = 노이즈
- 결측 283,140개가 가짜 데이터

LightGBM (v3)

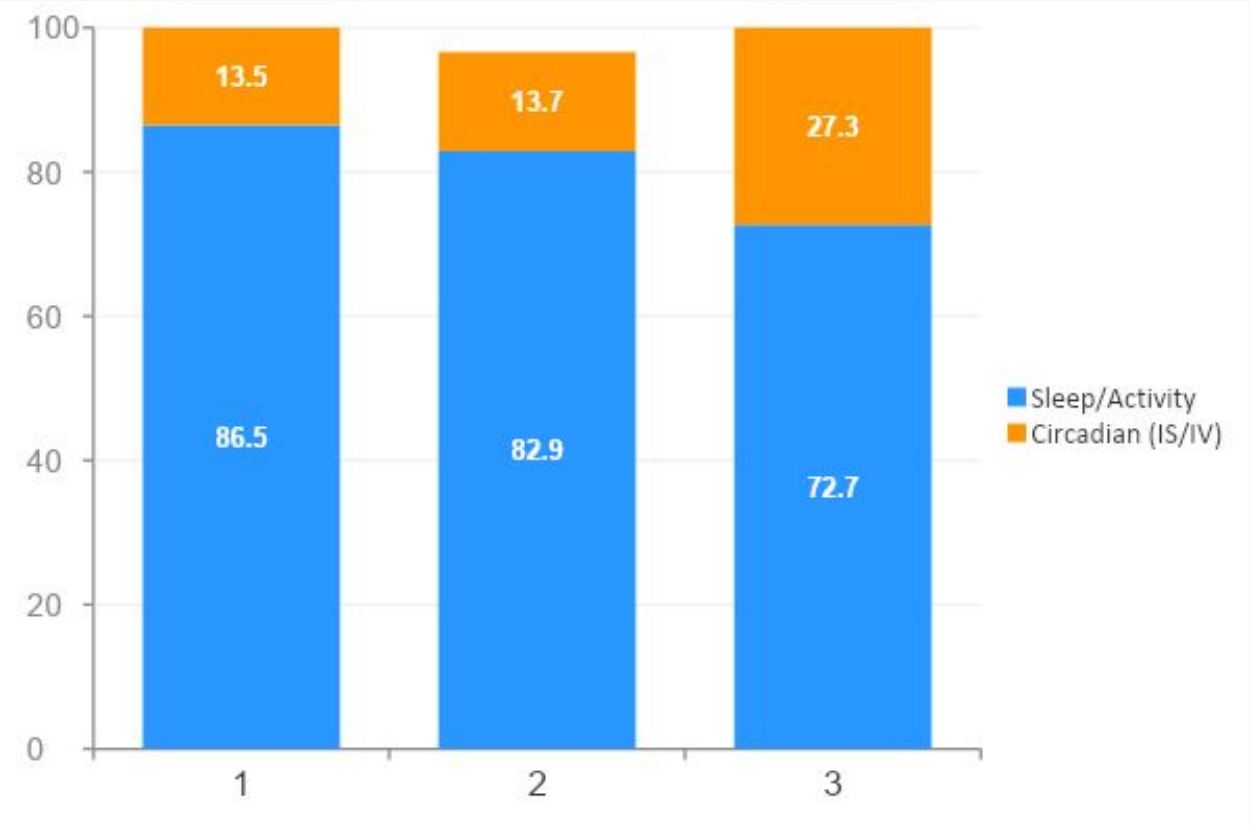
NaN을 트리 분기에서 직접 처리 → 결측 자체가 정보로 활용됨

AUC 0.5681

v1 대비 +0.0098 · 두 트랙 통틀어 최고 성능



써카디안 SHAP 13.5% → 27.3%



왜 두 배가 됐나

v1/v2는 결측을 채워서 IS/IV 신호가 섞임
v3는 NaN을 분리 처리해 신호가 선명해짐

의미

써카디안 리듬 불규칙성이
실제로 중요한 생체 신호임을 재확인

04 Track B — RandomForest 트랙

새 써카디안 지표(RA) 설계 방향 → AUC 0.5656

v3: 새 써카디안 피처 — RA & Morning Ratio

RA (Relative Amplitude)

표준 actigraphy 비모수 써카디안 지표

$$RA = (M10 - L5) / (M10 + L5)$$

M10 = 가장 활동적인 구간 평균 (morning+afternoon)
L5 = 가장 비활동적인 구간 (night)

해석: RA가 낮을수록 활동-휴식 리듬의 진폭이 작다 → 활동량 패턴이 밋밋해짐 → 우울 시 흔한 양상

morning_activity_ratio

= 아침 걸음수 / (아침+저녁 걸음수) — 아침형/저녁형 성향 측정

v3 결과

AUC 0.5642

v1 대비 +0.0059

같이 적용된 변경

- Linear interpolation imputation 시도 (person-level median이 더 나음으로 결론)
- StandardScaler를 CV fold 내부에서 fit (leakage 방지 강화)
- XGBoost 유지 (모델은 그대로, 피처만 추가)

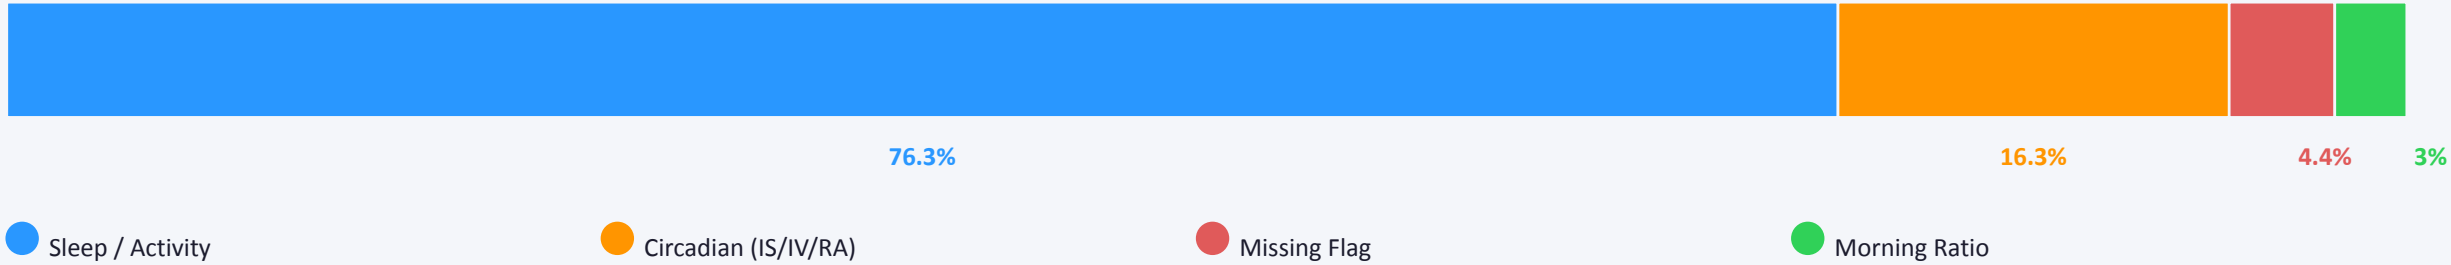
v4: RandomForest로 전환

AUC 0.5656

Track B 최고 성능 · v1 대비 +0.0073

두 트랙 전체 비교에서는 Track A의 LightGBM(0.5681)이 근소하게 앞섬

SHAP 피처 그룹 기여도 (v4 기준)



주목: Track B는 Missing flag 기여도(4.4%)가 Track A(v2 기준 3.3%)와 비슷한 수준 유지 — RandomForest도 flag를 어느 정도 활용함

Track B 추가 실험

시도했으나 효과 없었던 것들

Linear Interpolation

person-level median보다 낮음

시간 순서 기반 보간이 결측 패턴 자체의 정보(=신호)를 오히려 매끄럽게 지워버림

Within-person Z-score 정규화

효과 없음

개인별 표준화가 트리 기반 모델에서는 큰 의미가 없었음 (트리는 스케일에 비교적 둔감)

7일 평균 매칭

AUC 0.5564 (당일 매칭보다 낮음)

설문 시점과 가까운 1일 단위 매칭이 7일 평균보다 더 유효한 신호를 가짐

LightGBM (Track B 버전)

AUC 0.5574 (XGBoost보다 낮음)

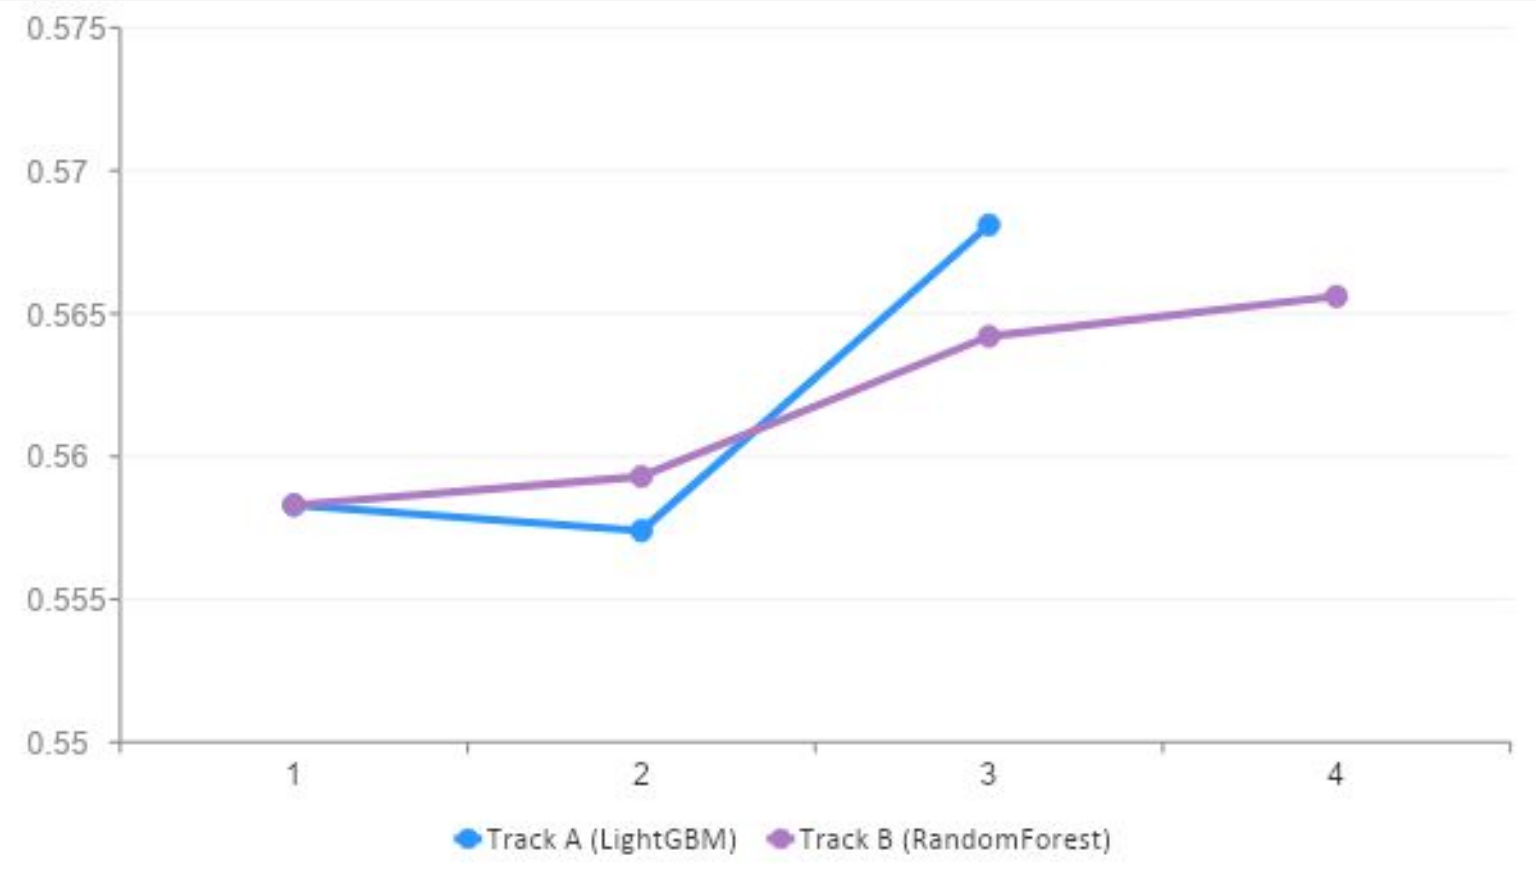
imputation을 유지한 채 모델만 LightGBM으로 바꿈 — Track A처럼 imputation을 제거하지 않아 효과 제한적 *

** Track A의 LightGBM(0.5681)과 다른 결과 — Track A는 imputation을 완전히 제거했고, Track B는 imputation을 유지한 채 모델만 교체함. 이 구현 차이가 상반된 결과의 원인으로 추정됨.*

05 두 트랙 종합 비교

AUC · SHAP · 장단점 정면 비교

전체 버전 AUC 흐름



Track A 최고

0.5681

v3 LightGBM

Track B 최고

0.5656

v4 RandomForest

최종 결론

Track A가 +0.0025 더 높음.
모델 구조 변경(LightGBM)이
피처 추가(RA)보다 효과적

SHAP 비교

최종 모델 SHAP 그룹 기여도 비교

구분	Sleep/Activity	Circadian	Missing Flag	기타	피처수	AUC
Track A — v3 (LightGBM)	72.7%	27.3% (IS/IV)	—	—	127개	0.5681
Track B — v4 (RandomForest)	76.3%	16.3% (IS/IV/RA)	4.4%	3.0% (Morning)	~131개	0.5656

Track A 특징

써카디안 기여도가 27.3%로 압도적으로 높음.

이유: LightGBM이 NaN을 별도 경로로 처리하면서
IS/IV의 순수 신호가 다른 피처와 섞이지 않고
더 명확하게 드러남.

→ 모델 구조가 피처 해석력 자체를 바꿈

Track B 특징

써카디안 16.3% + Morning ratio 3.0% = 19.3%로
조금 더 다양한 신호 분산.

RA 피처가 새로운 정보를 제공하지만
IS/IV 대비 압도적 우위는 아님.

→ 피처 다양화는 폭은 넓히지만 깊이는 제한적

Track A vs Track B — 장단점 정리

Track A — LightGBM

장점

- AUC 최고 (0.5681)
- Imputation 노이즈 완전 제거
- 구현이 상대적으로 단순 (피처 추가 불필요)
- 결측 자체가 신호로 활용됨

단점

- 써카디안 피처 종류가 IS/IV 2개로 제한적
- RA 등 추가 써카디안 지표 미탐색
- 모델 변경 효과가 데이터셋에 의존적일 수 있음

Track B — RandomForest

장점

- RA(Relative Amplitude) — 표준 actigraphy 지표 도입
- Morning ratio로 일주기 위상 선호도 측정
- 다양한 imputation 방식 비교 실험(보간 등)을 체계적으로 시도
- 피처 해석의 폭이 넓음

단점

- AUC가 Track A보다 낮음 (-0.0025)
- Imputation을 여전히 유지 → 노이즈 완전 해결 못함
- LightGBM 시도가 imputation 미제거로 저평가됐을 가능성

06 통합 다음 단계

두 트랙의 장점을 합친 v5 제안

통합 제안

v5 — 두 트랙의 장점 결합

Track A에서 가져올 것

LightGBM + Imputation 완전 제거

결측 자체를 신호로 활용하는 구조

Track B에서 가져올 것

RA + Morning Ratio 써카디안 피처

표준 actigraphy 지표로 신호 다양화

v5 — LightGBM + RA + Morning Ratio + IS/IV (imputation 없음)

두 트랙 모두에서 검증된 개선 요소만 결합한 차기 파이프라인

추가 탐색 방향

① **써카디안 고도화**

HR 데이터 확보 시 Forger ODE로 CBTmin/DLMO 추정

② **7일 vs 당일 매칭 재검증**

LightGBM 기준으로 매칭 방식 재실험

③ **모델 앙상블**

LightGBM(Track A) + RandomForest(Track B) 앙상블 시도

Summary

두 트랙에서 배운 것

01 모델 구조 변경 > 피처 추가

Track A(모델 변경, +0.0098)가 Track B(피처 추가, +0.0073)보다 효과적

02 RA는 유효한 신호이나 결정적이지 않음

새 써카디안 지표가 정보를 더하지만 imputation 문제 해결만큼 크진 않음

03 같은 실험도 구현 디테일에 따라 다른 결론

양쪽 LightGBM 결과가 정반대 — imputation 유지 여부가 핵심 변수였음

04 두 트랙은 상호보완적

v5에서 결합 시 추가적인 AUC 개선 가능성 존재